多元线性回归中“控制变量”的数学推证与随机仿真练习

数学模型课程

目录

I 理论部分：控制变量的数学推证 **2**

1 问题设定 **2**

2 最小二乘估计的代数解 **2**

3 残差化推证：Frisch-Waugh-Lovell 定理 **3**

4 偏相关系数 **3**

5 推广到多个控制变量 **4**

6 统计检验 **4**

7 小结 **4**

II 练习题目：随机仿真与验证 **5**

8 题目背景 **5**

9 变量设定 **5**

10 随机模拟算法 **5**

11 实施步骤与要求 **6**

12 实验报告要求 **6**

Part I

理论部分：控制变量的数学推证

1 问题设定

设因变量为 Y，关注的自变量为 X_1，需要控制的变量构成向量 $\mathbf{Z} = (X_2, \dots, X_k)^{\mathsf{T}}$。为简化记号，先考虑只控制一个变量 X_2 的情形，最后推广到一般情形。所有变量均已中心化（均值为零），于是模型不含截距项：

$$Y = \beta_1 X_1 + \beta_2 X_2 + \varepsilon. \tag{1}$$

记样本量为 n，样本向量用小写字母表示：$\mathbf{y}, \mathbf{x}_1, \mathbf{x}_2 \in \mathbb{R}^n$。中心化后 $\mathbf{1}^{\mathsf{T}}\mathbf{y} = \mathbf{1}^{\mathsf{T}}\mathbf{x}_1 = \mathbf{1}^{\mathsf{T}}\mathbf{x}_2 = 0$。

定义 1 (内积与范数)**.** 对 $\mathbf{u}, \mathbf{v} \in \mathbb{R}^n$，定义 $\langle \mathbf{u}, \mathbf{v} \rangle = \mathbf{u}^{\mathsf{T}}\mathbf{v}$，$\|\mathbf{u}\|^2 = \langle \mathbf{u}, \mathbf{u} \rangle$。样本相关系数 $r_{uv} = \dfrac{\langle \mathbf{u}, \mathbf{v} \rangle}{\|\mathbf{u}\|\,\|\mathbf{v}\|}$。

2 最小二乘估计的代数解

定理 1 (正规方程)**.** *模型 (1) 的最小二乘估计 $(\hat\beta_1, \hat\beta_2)$ 是如下正规方程的解：*

$$\begin{pmatrix} \|\mathbf{x}_1\|^2 & \langle \mathbf{x}_1, \mathbf{x}_2 \rangle \\ \langle \mathbf{x}_1, \mathbf{x}_2 \rangle & \|\mathbf{x}_2\|^2 \end{pmatrix} \begin{pmatrix} \hat\beta_1 \\ \hat\beta_2 \end{pmatrix} = \begin{pmatrix} \langle \mathbf{x}_1, \mathbf{y} \rangle \\ \langle \mathbf{x}_2, \mathbf{y} \rangle \end{pmatrix}. \tag{2}$$

证明. 最小化目标 $Q(\beta_1, \beta_2) = \|\mathbf{y} - \beta_1\mathbf{x}_1 - \beta_2\mathbf{x}_2\|^2$。对 β_1, β_2 求偏导并令其为零：

$$\frac{\partial Q}{\partial \beta_1} = -2\langle \mathbf{x}_1, \mathbf{y} - \beta_1\mathbf{x}_1 - \beta_2\mathbf{x}_2 \rangle = 0, \tag{3}$$

$$\frac{\partial Q}{\partial \beta_2} = -2\langle \mathbf{x}_2, \mathbf{y} - \beta_1\mathbf{x}_1 - \beta_2\mathbf{x}_2 \rangle = 0. \tag{4}$$

整理即得 (2)。 □

定理 2 (偏回归系数的显式表达)**.** *设 $\mathbf{x}_1, \mathbf{x}_2$ 线性无关，则*

$$\hat\beta_1 = \frac{\|\mathbf{x}_2\|^2 \langle \mathbf{x}_1, \mathbf{y} \rangle - \langle \mathbf{x}_1, \mathbf{x}_2 \rangle \langle \mathbf{x}_2, \mathbf{y} \rangle}{\|\mathbf{x}_1\|^2 \|\mathbf{x}_2\|^2 - \langle \mathbf{x}_1, \mathbf{x}_2 \rangle^2}. \tag{5}$$

用相关系数表示，令 $r_{ij} = r_{x_i x_j}$，$r_{iy} = r_{x_i y}$，则

$$\hat\beta_1 = \frac{r_{1y} - r_{12} r_{2y}}{1 - r_{12}^2} \cdot \frac{\|\mathbf{y}\|}{\|\mathbf{x}_1\|}. \tag{6}$$

证明. 由 Cramer 法则解 (2)：

$$\hat\beta_1 = \frac{\|\mathbf{x}_2\|^2 \langle \mathbf{x}_1, \mathbf{y} \rangle - \langle \mathbf{x}_1, \mathbf{x}_2 \rangle \langle \mathbf{x}_2, \mathbf{y} \rangle}{\|\mathbf{x}_1\|^2 \|\mathbf{x}_2\|^2 - \langle \mathbf{x}_1, \mathbf{x}_2 \rangle^2}.$$

分子分母同除以 $\|\mathbf{x}_1\|^2\|\mathbf{x}_2\|^2$：

$$\hat\beta_1 = \frac{\langle \mathbf{x}_1, \mathbf{y} \rangle / \|\mathbf{x}_1\|^2 - r_{12}\, \langle \mathbf{x}_2, \mathbf{y} \rangle / \|\mathbf{x}_2\|^2}{1 - r_{12}^2}.$$

再将 $\langle \mathbf{x}_1, \mathbf{y} \rangle = r_{1y}\|\mathbf{x}_1\|\|\mathbf{y}\|$，$\langle \mathbf{x}_2, \mathbf{y} \rangle = r_{2y}\|\mathbf{x}_2\|\|\mathbf{y}\|$ 代入，整理即得

$$\hat{\beta}_1 = \frac{r_{1y} - r_{12}r_{2y}}{1 - r_{12}^2} \cdot \frac{\|\mathbf{y}\|}{\|\mathbf{x}_1\|}.$$

□

注 1 (“控制”的含义)**.** 式 (6) 的分子 $r_{1y} - r_{12}r_{2y}$ 正是从 r_{1y} 中扣除了 X_2 与 X_1 的重叠（r_{12}）以及 X_2 与 Y 的重叠（r_{2y}）所带来的部分。分母 $1 - r_{12}^2$ 是对 X_1 自身变异中“不被 X_2 解释”的比例的修正。因此 $\hat{\beta}_1$ 度量的是 X_1 中与 X_2 正交的那部分对 Y 的净效应。

3 残差化推证：Frisch-Waugh-Lovell 定理

下面给出“先剔除控制变量影响、再做回归”的严格证明。

定义 2 (残差化算子)**.** 设 $\mathbf{M}_2 = \mathbf{I} - \mathbf{P}_2$，其中 $\mathbf{P}_2 = \mathbf{x}_2(\mathbf{x}_2^\top \mathbf{x}_2)^{-1}\mathbf{x}_2^\top$ 是向 $\mathrm{span}(\mathbf{x}_2)$ 的投影矩阵。称 $\mathbf{M}_2\mathbf{u}$ 为 $\mathbf{u}$ 对 $\mathbf{x}_2$ 回归后的残差。

定理 3 (FWL 定理，单控制变量情形)**.** 模型 *(1)* 的 $\hat{\beta}_1$ 等于如下简单回归的斜率：用 $\mathbf{M}_2\mathbf{y}$ 对 $\mathbf{M}_2\mathbf{x}_1$ 做无截距回归，即

$$\hat{\beta}_1 = \frac{\langle \mathbf{M}_2\mathbf{x}_1, \mathbf{M}_2\mathbf{y} \rangle}{\|\mathbf{M}_2\mathbf{x}_1\|^2}. \tag{7}$$

证明. 由投影矩阵性质 $\mathbf{M}_2^\top = \mathbf{M}_2$，$\mathbf{M}_2^2 = \mathbf{M}_2$，且 $\mathbf{M}_2\mathbf{x}_2 = \mathbf{0}$，故

$$\langle \mathbf{M}_2\mathbf{x}_1, \mathbf{M}_2\mathbf{y} \rangle = \mathbf{x}_1^\top \mathbf{M}_2 \mathbf{y} = \langle \mathbf{x}_1, \mathbf{y} \rangle - \frac{\langle \mathbf{x}_1, \mathbf{x}_2 \rangle \langle \mathbf{x}_2, \mathbf{y} \rangle}{\|\mathbf{x}_2\|^2},$$

$$\|\mathbf{M}_2\mathbf{x}_1\|^2 = \langle \mathbf{x}_1, \mathbf{x}_1 \rangle - \frac{\langle \mathbf{x}_1, \mathbf{x}_2 \rangle^2}{\|\mathbf{x}_2\|^2}.$$

于是

$$\frac{\langle \mathbf{M}_2\mathbf{x}_1, \mathbf{M}_2\mathbf{y} \rangle}{\|\mathbf{M}_2\mathbf{x}_1\|^2} = \frac{\|\mathbf{x}_2\|^2 \langle \mathbf{x}_1, \mathbf{y} \rangle - \langle \mathbf{x}_1, \mathbf{x}_2 \rangle \langle \mathbf{x}_2, \mathbf{y} \rangle}{\|\mathbf{x}_1\|^2 \|\mathbf{x}_2\|^2 - \langle \mathbf{x}_1, \mathbf{x}_2 \rangle^2},$$

与定理 2 的 $\hat{\beta}_1$ 完全一致。 □

注 2. 该定理说明：控制 X_2 的数学操作，等价于把 Y 和 X_1 中能被 X_2 线性解释的部分都减掉，只保留两者“净”的部分做回归。这是“控制变量”最直观的代数解释。

4 偏相关系数

定义 3 (偏相关系数)**.** 在控制 X_2 的条件下，Y 与 X_1 的偏相关系数定义为残差 $\mathbf{M}_2\mathbf{y}$ 与 $\mathbf{M}_2\mathbf{x}_1$ 的样本相关系数：

$$r_{1y\cdot 2} = \frac{\langle \mathbf{M}_2\mathbf{x}_1, \mathbf{M}_2\mathbf{y} \rangle}{\|\mathbf{M}_2\mathbf{x}_1\| \, \|\mathbf{M}_2\mathbf{y}\|}. \tag{8}$$

命题 1 (偏相关的显式公式)**.**

$$r_{1y\cdot 2} = \frac{r_{1y} - r_{12}r_{2y}}{\sqrt{1 - r_{12}^2}\sqrt{1 - r_{2y}^2}}. \tag{9}$$

证明. 由定理 3 的证明，$\langle \mathbf{M}_2\mathbf{x}_1, \mathbf{M}_2\mathbf{y}\rangle = \|\mathbf{x}_1\|\|\mathbf{y}\|(r_{1y} - r_{12}r_{2y})$，

$$\|\mathbf{M}_2\mathbf{x}_1\|^2 = \|\mathbf{x}_1\|^2(1 - r_{12}^2), \qquad \|\mathbf{M}_2\mathbf{y}\|^2 = \|\mathbf{y}\|^2(1 - r_{2y}^2).$$

代入定义即得。 □

注 3 (与回归系数的关系). 比较定理 2 与命题 4 可得

$$\hat{\beta}_1 = r_{1y\cdot 2} \cdot \frac{\|\mathbf{M}_2\mathbf{y}\|}{\|\mathbf{M}_2\mathbf{x}_1\|}.$$

即偏回归系数等于偏相关系数乘以残差尺度之比，这与简单回归中“斜率 = 相关系数 × 标准差之比”的结构完全平行。

5 推广到多个控制变量

设控制变量矩阵 $\mathbf{Z} = (\mathbf{x}_2, \ldots, \mathbf{x}_k) \in \mathbb{R}^{n\times(k-1)}$，$\mathbf{M} = \mathbf{I} - \mathbf{Z}(\mathbf{Z}^\mathsf{T}\mathbf{Z})^{-1}\mathbf{Z}^\mathsf{T}$。则 FWL 定理推广为

$$\hat{\beta}_1 = \frac{\langle \mathbf{M}\mathbf{x}_1, \mathbf{M}\mathbf{y}\rangle}{\|\mathbf{M}\mathbf{x}_1\|^2}, \tag{10}$$

即把 Y 与 X_1 分别对全部控制变量回归取残差,再做简单回归。偏相关定义为 $r_{1y\cdot\mathbf{Z}} = \dfrac{\langle \mathbf{M}\mathbf{x}_1, \mathbf{M}\mathbf{y}\rangle}{\|\mathbf{M}\mathbf{x}_1\|\,\|\mathbf{M}\mathbf{y}\|}$。

6 统计检验

在正态误差假设 $\varepsilon \sim N(0, \sigma^2\mathbf{I})$ 下，$\hat{\beta}_1$ 服从正态分布，其标准误为

$$\mathrm{se}(\hat{\beta}_1) = \hat{\sigma}\Big/\|\mathbf{M}\mathbf{x}_1\|, \qquad \hat{\sigma}^2 = \frac{\|\mathbf{M}\mathbf{y} - \hat{\beta}_1\mathbf{M}\mathbf{x}_1\|^2}{n-k}. \tag{11}$$

检验 $H_0 : \beta_1 = 0$ 的统计量为

$$t = \frac{\hat{\beta}_1}{\mathrm{se}(\hat{\beta}_1)} \sim t_{n-k}, \tag{12}$$

等价地，t^2 可由偏相关系数表示为 $t^2 = (n-k)\dfrac{r_{1y\cdot\mathbf{Z}}^2}{1 - r_{1y\cdot\mathbf{Z}}^2}$。这从检验层面再次说明：$\beta_1$ 的显著性完全由“净相关”决定。

7 小结

(1) 多元回归中 $\hat{\beta}_1$ 的代数表达式，本质是从 r_{1y} 中扣除 X_2 带来的重叠。

(2) FWL 定理给出“控制”的操作性定义：残差化后再回归。

(3) 偏相关刻画净关联强度，偏回归系数 = 偏相关 × 残差尺度比。

(4) t 检验的原假设是“控制其他变量后 X_1 无线性影响”，其统计量只依赖偏相关。

Part II

练习题目：随机仿真与验证

8 题目背景

某高校希望研究学生**日均睡眠时长**对**期末平均成绩**的影响。由于睡眠时长与自习时长、手机娱乐时长等因素相互关联，直接做简单回归会把其他变量的影响混入睡眠的系数中。请采用多元线性回归，在控制自习时长和手机娱乐时长的条件下，判断睡眠时长对成绩的净影响，并通过随机仿真生成数据、用 FWL 残差化方法进行验证。

9 变量设定

设样本量为 $n = 60$，变量如下：

变量	含义	角色
Y	期末平均成绩	因变量
X_1	日均睡眠时长（小时）	关注的自变量
X_2	日均自习时长（小时）	控制变量
X_3	日均手机娱乐时长（小时）	控制变量

10 随机模拟算法

数据按如下结构生成，确保 X_1, X_2, X_3 之间存在相关（从而体现“控制”的必要性），且真实系数已知，便于验证估计是否接近真值。

要求 1 (数据生成算法)**.** ***步 1.*** *设定随机种子（例如 `set.seed(2024)`）以保证结果可复现。*

步 2. *生成控制变量与关注变量的联合分布：令*

$$\begin{pmatrix} X_2 \\ X_3 \\ X_1 \end{pmatrix} \sim N_3(\boldsymbol{\mu}, \Sigma), \quad \boldsymbol{\mu} = \begin{pmatrix} 3 \\ 2 \\ 7 \end{pmatrix}, \quad \Sigma = \begin{pmatrix} 1.0 & 0.3 & -0.5 \\ 0.3 & 1.0 & -0.2 \\ -0.5 & -0.2 & 1.0 \end{pmatrix}.$$

这里 Σ 的非对角元刻画了“自习多则睡眠少”“手机多则自习略多”等关联。

步 3. *生成误差项：$\varepsilon \sim N(0, \sigma^2)$，取 $\sigma = 5$。*

步 4. *按真实模型生成因变量：*

$$Y = 60 + 2X_1 + 1.5X_2 - 1X_3 + \varepsilon.$$

因此真实偏回归系数为 $\beta_1 = 2$（睡眠净效应）、$\beta_2 = 1.5$、$\beta_3 = -1$，截距 $\beta_0 = 60$。

步 5. *将 (Y, X_1, X_2, X_3) 保存为 CSV 文件 `sleep_score.csv`。*

注 4. *由于 X_1 与 X_2 负相关（-0.5），而 X_2 对 Y 有正效应，简单回归 $Y \sim X_1$ 中 X_1 的系数会被“拉低”，偏离真值 2。这正是需要控制变量、并用偏回归系数识别净效应的原因。*

11 实施步骤与要求

要求 2 (步骤一：数据生成与描述统计). 按第 *3* 节算法生成数据并保存。计算四个变量的均值、标准差，以及 4×4 相关矩阵。**要求：**报告相关矩阵，指出 X_1 与 X_2、X_1 与 X_3 的相关系数符号与大小，说明控制变量确有共线关联。

要求 3 (步骤二：简单回归（不控制）). 用 Y 对 X_1 做一元线性回归，报告 $\hat{\beta}_1^{simple}$、标准误、t 值、p 值与 R^2。**要求：**将 $\hat{\beta}_1^{simple}$ 与真值 2 比较，解释偏差方向为何与 X_1、X_2 的负相关一致。

要求 4 (步骤三：多元回归（控制）). 建立模型 $Y=\beta_0+\beta_1X_1+\beta_2X_2+\beta_3X_3+\varepsilon$，用最小二乘估计。报告三个偏回归系数、标准误、$t$ 值、p 值与调整 R^2。**要求：**写出 $\hat{\beta}_1$ 的数值，解释“保持 X_2, X_3 不变，睡眠每增加 *1* 小时，成绩平均变化多少”；判断其是否接近真值 2，并检验 $H_0:\beta_1=0$。

要求 5 (步骤四：FWL 残差化验证). 用最小二乘分别把 Y 和 X_1 对控制变量 (X_2, X_3) 回归，得到残差 $\mathbf{e}_Y$ 与 $\mathbf{e}_{X_1}$；用 $\mathbf{e}_Y$ 对 $\mathbf{e}_{X_1}$ 做无截距简单回归，记录斜率 $\hat{\beta}_1^{FWL}$。**要求：**给出 $\hat{\beta}_1^{FWL}$ 与步骤三 $\hat{\beta}_1$ 的数值，验证二者在数值误差范围内相等（例如差值绝对值小于 10^{-8}），并说明这正是 *FWL* 定理的结论。

要求 6 (步骤五：偏相关与 t 检验的等价性). 计算控制 (X_2, X_3) 后 X_1 与 Y 的偏相关系数 $r_{1y\cdot 23}$（可直接用两残差的相关系数）；用公式

$$t^2=(n-k)\frac{r_{1y\cdot 23}^2}{1-r_{1y\cdot 23}^2},\qquad k=4$$

手算 t 值，并与步骤三软件输出的 t 值比较。**要求：**报告 $r_{1y\cdot 23}$、手算 t、软件 t，验证二者一致（误差小于 10^{-6}），并说明 t 检验只依赖净相关。

要求 7 (步骤六：简单回归与多元回归对比讨论). 将步骤二与步骤三中 X_1 的系数并列比较。**要求：**定量说明“控制变量”使系数从多少变到多少、方向是否改变；结合 X_1 与 X_2 的相关性解释偏差来源；讨论若遗漏 X_3（手机时长）这类混淆变量，对 $\hat{\beta}_1$ 可能产生何种偏误。

要求 8 (步骤七：仿真重复与抽样分布（可选加分）). 将第 *3* 节算法重复 $M=500$ 次，每次记录 $\hat{\beta}_1^{simple}$ 与 $\hat{\beta}_1^{multiple}$。**要求：**画出两个估计量的直方图，报告各自均值与标准差；说明哪个估计量围绕真值 2 波动、哪个系统性偏离，从而用仿真印证“控制变量消除混淆偏误”。

12 实验报告要求

提交一份实验报告，包含以下部分：

(1) **问题与模型：**复述研究问题、变量角色与总体模型。

(2) **数据生成：**给出随机模拟算法、随机种子、参数设定，附相关矩阵。

(3) **简单回归结果：**系数表与对偏差的解释。

(4) **多元回归结果：**系数表、$\hat{\beta}_1$ 的解释与假设检验结论。

(5) **FWL 验证**：残差化步骤、两个 $\hat{\beta}_1$ 的数值对比与结论。

(6) **偏相关验证**：$r_{1y\cdot 23}$、手算 t 与软件 t 的对比。

(7) **讨论**：控制前后系数变化、遗漏变量的偏误方向、方法的局限（相关不等于因果）。

(8) **附录**：完整代码（R/Python/Stata 均可）与数据文件说明。

注 5 (提交物清单).

- 报告 *PDF*（含上述八部分）；
- 数据文件 *sleep_score.csv*；
- 可运行脚本一份，脚本开头设定随机种子，运行后能复现报告中的全部数值。